





Journée formation IA en biologie médicale Exemples d'application

Dr Alexandre Godmer Dr Guillaume Bachelot





Exemples

Spectrométrie de masse et intelligence artificielle : exemples 1 et 2

qPCR et intelligence artificielle : exemple 3

Exemples 1 et 2

Examen microscopique

24h culture

48h identification/antibiogramme



















Exemples 1 et 2



Matrix Assisted Laser Desorption Ionization Time Of Flight



Quelques minutes versus quelques heures (méthodes biochimiques, moléculaires ...)

Objectif : améliorer les performances du MALDI-TOF SM à l'aide des techniques de Machine Learning Développement d'outils bio-informatiques facilement utilisables pour la communauté scientifique et la routine

Exemples 1 et 2 Détecteur Traitement du signal Intensité **Séparation Tube** (time of flight) Laser Accélération **Ionisation** Cible m/z Désorption Matrice + échantillon Virulence **Identification** (Co-cristallisation) Résistance

Objectif : améliorer les performances du MALDI-TOF SM à l'aide des techniques de Machine Learning Développement d'outils bio-informatiques facilement utilisables pour la communauté scientifique et la routine


Exemples 1 et 2

B


- Nouvelles bases de données
- Nouveaux algorithmes :
- → Machine Learning, MSI

Problématique des techniques d'IA et biologiste :


- programmation : challenge, quelles méthodes ?
- solution « tout en un » : payant, l'utilisateur n'a pas la main et non exhaustivité des méthodes



- Package R open-source, des pipelines d'analyse complets, faciles à utiliser
- 15 pipelines d'analyse avec des techniques de Machine Learning
- Illustré par deux exemples disponibles sur le CRAN



Comparison of ML-methods to estimate a classification model ranked by mean accuracy on test datasets




Exemple 1 : complexe Mvcobacterium abscessus

Journal of Antimicrobial Chemotherapy

Mycobacterium abscessus: a new antibiotic nightmare

Complexe M. abscessus (3 sous-espèces): abscessus, bolletii, massiliense

Clarithromycine : traitement de référence




Identification rapide = adaptation précoce du traitement

Exemple 1 : complexe *Mycobacterium abscessus*

Production de données





Traitement des données

	Pic 1 (m/z)	Pic (m/z)	Pic n (m/z)
Souche A			
Souche B			
Souche			
Souche n			

Modèle de classification (MSclassifR)

41 souches du complexe *M. abscessus* provenant du CNR des mycobactéries (identification moléculaire)

- M. abscessus (15 souches)
- *M. bolletii* (7 souches)
- *M. massiliense* (9 souches)

COH délai de culture : 5 ± 2 jours


1001 spectres

- M. abscessus (633 spectres)
- M. bolletii (164 spectres)
- *M. massiliense* (204 spectres)

Traitement du signal Matrice d'intensités

Sélection de variables (pics discriminants) Algorithmes mathématiques de Machine Learning


Exemple 1 : complexe Mycobacterium abscessus



Création de 15 modèles de Machine learning :

6 modèles avec justesse (accuracy) > 0,99 versus 0,61 pour la méthode utilisée en routine au laboratoire

Exemple 1 : complexe Mycobacterium abscessus



Création de 15 modèles de Machine learning :

6 modèles avec justesse (accuracy) > 0,99 versus 0,61 pour la méthode utilisée en routine au laboratoire

Exemple 2 : Clostridioides difficile

- Bactérie anaérobie à Gram +
- Pathogénicité liée à la production de toxines :
 - Toxine A entérotoxine (TcdA)
 - Toxine B cytotoxine (TcdB)
 - o **Toxine binaire** : facteur de virulence supplémentaire ? (20% des souches toxinogènes)
- Clinique :
 - variable : portage asymptomatique, diarrhée bénigne à sévère, colite pseudomembraneuse
 - ∘ spores → persistance environnement → récidives
- Infections nosocomiales (1er rang aux US, 9e en France), infections communautaires en augmentation
- Grandes épidémies liées à un clone particulier clone PCR-ribotype 027 (binaire +)


Diagnostic = méthodes moléculaires sur prélèvement + autres techniques Analyse des données épidémiologiques = méthodes moléculaires sur culture





Exemple 2 : Clostridioides difficile

Production de données



Traitement des données

	Pic 1 (m/z)	Pic (m/z)	Pic n (m/z)
Souche A			
Souche B			
Souche			
Souche n			

Modèle de classification IA

C. difficile (n = 201 souches, 50 PCR-ribotypes) du CNR Cd

- Souches tox + (n = 151 souches, 32 PCR-ribotypes)
- Souches tox binaire + (n = 46 souches, 8 PCR-ribotypes)
- Souches hypervirulentes (n = 22 souches, 3 PCR-ribotypes)


Extraction totale (extraction chimique)
Acquisition MALDI-TOF SM (minimum : 20 spectres par souches)

4635 spectres de C. difficile

- Souches tox + (n = 3439 spectres) (prévalence = 74%)
- Souches tox binaire + (n = 1032 spectres) (prévalence = 22%)
- Souches hypervirulentes (n = 487 spectres) (prévalence = 10%)

Traitement du signal Matrice d'intensités

Deep Learning (réseau de neurones)



Alexandre Godmer

Modèles

Alexandre Godmer

Conclusion, exemples 1 et 2

- création de modèles performants
- complémentarité avec les méthodes existantes
- virulence : preuve de concept sur *C. difficile*
- gain de temps, coût +++
- nécessité d'évaluer ces modèles sur des jeux de données externes (en cours)
- les données = le nerf de la guerre (merci aux CNR +++) :
 - o qualité
 - o quantité

Répondre à une problématique

Spectrométrie de masse et intelligence artificielle : exemples 1 et 2

qPCR et intelligence artificielle : exemple 3

OPEN

Machine learning to improve the interpretation of intercalating dye-based quantitative PCR results


A. Godmer^{1,2|M|}, J. Bigot³, Q. Giai Gianetto^{4,5}, Y. Benzerara¹, N. Veziris^{1,2}, A. Aubry^{2,6}, J. Guitard³ & C. Hennequin³


scientific reports

Context (1): Mucormycosis infection

Mucormycosis infections = opportunistic fungal infection


- → filamentous fungi (family of Zygomycetes, order of Mucorales)
- → ~27 species under Mucorales are associated with human infections (*Rhizopus, Mucor, Absidia, Rhizomucor*)
- → multiples localisations: lung, brain, disseminated, skin
- → risk factors :diabetes, haematological malignancy, solid organ transplant, burn (immunodépression +++)
- \rightarrow prevalence: 400 in 2020






Mucormycosis = associated to high mortality (20-60%)

Context (2): Mucormycosis traitement



Mucormycosis = therapeutic urgency

Context (3): mucormycosis diagnosis




qPCR = contributory element for a rapid complicated diagnosis +++


Quantitative PCR = Real-time PCR = qPCR


- → use of fluorescent probes that bind to double-stranded DNA (SYBER technology)
- \rightarrow allows monitoring of the amount of DNA produced in the reaction medium (\neq end-point PCR)


http://www.geocities.ws/jsonnentag/iguana/pcr.htm

Measures the number of amplicons: portion of DNA defined by a pair of primers











Objective


Evaluate the contribution of implementing a ML-based classification approach to the interpretation of the plots (amplification and melting curves) by comparing the performances of the "visual reading" and ML into qPCR results interpretation

Methods



Methods: (A) routine based approach







Visual reading **Amplification curve** Raw fluorescence Melting curve



Methods: (A) routine based approach



Methods: application to qPCR mucor (B) ML-based approach




First question: how to transform these curves into informative numerical values?

Methods: application to qPCR mucor (B) ML-based approach


First question: how to transform these curves into informative numerical values?

Cycles



flattening of the curve


Methods: application to qPCR mucor (B) ML-based approach



- Feature selection (3 ML algorithms):
- → determining which features are informative
- Resampling method (3 methods)
- → positive events are rare = difficulty of a model to recognize its events because trained on the majority (negative) class
- ML based algorithms (4 algorithms)
- 50 iterations : check that the results are not random


Comprehensive analysis pipeline that considers class imbalance robustness checks of the results

Results: (B) ML-based approach




Many pipelines with Kappa coefficient > 0.80


Results: (B) ML-based approach



Many pipermes with Kappa coefficient > 0.80

Example: (B) ML-based approach






Wisdom of crowds:


a crowd of independent people with differing opinions is more accurate than the opinion of a single expert!

Methods: (B) ML-based approach



Results: (B) ML-based approach

i Down Raw **Smote iii** Up




Diversity of the meta-classifiers 6/48 total agreement on the external dataset

perfect!

Conclusion

- → ML approach enables to reliably and rapidly classify qPCR without the need of clinical, microbiological and radiological data
- → time savings +++
- → avaible online: http://gepamy-sat.asso.st/
- → evaluation of the method on another qPCR




Conclusions, perspectives

Codage et intelligence artificielle:

Nouveaux horizons passionnants dans la recherche médicale Aide au diagnostic médical dans la pratique quotidienne (futur proche ?)



https://scai.sorbonne-universite.fr/







Conclusions, perspectives

Limites matérielles (loi de Moore ?)

40 years of Processor Performance



https://www.journaldugeek.com/2022/07/11/les-puces-3d-dibm-vont-elles-ressusciter-la-loi-de-moore/



Limites pour reproduire l'homme

Limites éthiques

Alexandre Godmer